电力巡检算子 SwiGLU

自定义算子工程

通过率： **34%** 通过人数： **22** 尝试人数： **64** 开始答题 提交开源仓

题目内容

描述

电力巡检 SwiGLU 算子

一、赛题背景

无人机输电线路巡检场景中，机载昇腾边缘NPU需实时运行ViT视觉模型，完成绝缘子缺陷、销钉脱落、导线断股等异常识别。ViT各Transformer模块采用SwiGLU作为激活单元以提升细粒度缺陷特征表达能力，但受限于机载算力与功耗预算，拆解实现的组合算子会带来访存开销与推理延迟，影响巡检图像流的实时处理帧率。本题要求使用Ascend C实现SwiGLU算子，替换ViT中的组合算子实现，服务于边缘视觉模型的实时推理。

二、算子功能描述

SwiGLU算子对输入张量做两路独立的线性变换（均含偏置），其中一路经过Swish（SiLU）激活后，与另一路线性变换结果做逐元素相乘（门控），得到最终输出。两路线性变换的输入输出维度相同，均等于输入特征维度。

三、核心定义与约束

3.1 参考算子

参考论文：Shazeer, "GLU Variants Improve Transformer", 2020

3.2 输入输出与属性总览

类型	参数名	类型	维度形状	支持数据类型	数据格式	备注
INPUT（必选）	input_x	tensor	(..., d)	float16	-	输入特征张量，支持任意前置维度（如批次、序列长度）

类型	参数名	类型	维度形状	支持数据类型	数据格式	备注
INPUT（必选）	weight_1	tensor	(d, d)	float16	-	linear_1 权重矩阵
INPUT（必选）	bias_1	tensor	(d,)	float16	-	linear_1 偏置向量
INPUT（必选）	weight_2	tensor	(d, d)	float16	-	linear_2 权重矩阵
INPUT（必选）	bias_2	tensor	(d,)	float16	-	linear_2 偏置向量
OUTPUT（输出）	output	tensor	(..., d)	float16	-	门控输出张量，形状与input_x一致

3.3 关键输入约束

维度取值范围（均为正整数）：

- 特征维度 d（即 input_x 最后一维）∈ [1, 8192]
- input_x 支持任意数量的前置维度（batch维、序列维等），前置维度乘积记为 M，M ∈ [1, 1048576]

非对齐场景兼容： d 及前置各维度均可能为非32整倍数，算子需适配内存/数据非32字节对齐的场景

数值取值约束： 输入张量、权重、偏置的数值取值范围不超出 float16 的原生表达范围

权重形状约束：

- weight_1、weight_2 均为方阵，形状为 (d, d)
- bias_1、bias_2 形状均为 (d,)
- 所有输入张量数据类型均为 float16
- weight_1/weight_2 的存储布局为 (out_dim, in_dim)

数据类型约束： 仅支持 float16

3.4 数学公式与计算规则

第一路线性变换（带偏置）：

$$z_1 = xW_1^\top + b_1$$

Swish（SiLU）激活（β=1）：

$$\text{Swish}(z_1) = z_1 \cdot \sigma(z_1) = \frac{z_1}{1 + e^{-z_1}}$$

第二路线性变换（带偏置）：

$$z_2 = xW_2^\top + b_2$$

SwiGLU 输出（逐元素相乘）：

$$\text{SwiGLU}(x) = \text{Swish}(z_1) \odot z_2 = \big(z_1 \cdot \sigma(z_1)\big) \odot \big(xW_2^\top + b_2\big)$$

其中：

- $\sigma(\cdot)$ 为 Sigmoid 函数
- $\odot$ 为逐元素（Hadamard）乘法
- $W_1, W_2 \in \mathbb{R}^{d \times d}$，$b_1, b_2 \in \mathbb{R}^{d}$，$d$ 为 dimension

3.5 输出要求

- 输出张量形状与输入张量 input_x 完全一致（含所有前置维度）
- 输出数据类型与输入数据类型相同
- 输出张量为两路线性变换门控融合后的计算结果

四、规则要求

精度要求：计算结果需满足以下精度误差要求（float16，混合误差判定）：

$$|y_{\text{out}} - y_{\text{golden}}| \le \text{atol} + \text{rtol} \times |y_{\text{golden}}|$$

其中 **atol** = 1×10^{-3}，**rtol** = 1×10^{-3}，逐元素比较，全部元素通过方判定该用例通过，等价于：

```
numpy.allclose(out, golden, rtol=1e-3, atol=1e-3)
```

五、示例说明

> 以下示例统一取 `weight_1 = I`（单位矩阵），`bias_1 = 0`，`weight_2 = I`，`bias_2 = 0`（示例2除外），即 $z_1 = x$，$z_2 = x$，此时 SwiGLU 退化为逐元素计算 $y = x \cdot \sigma(x) \cdot x$，便于直接验证核心激活计算逻辑。

示例 1：基础计算（float16类型，1D）

输入 x：tensor ([1.0, 2.0, 3.0])，dtype=float16，shape=[3]，weight_1=I，bias_1=0，weight_2=I，bias_2=0

输出 y：tensor ([0.731, 3.521, 8.570])，dtype=float16，shape=[3]

示例 2：非单位权重场景（float16，完整线性变换）

输入 x：tensor ([1.0, 2.0])，dtype=float16，shape=[2]
输入 weight_1：[[1.0, 0.0], [0.0, 1.0]]，bias_1：[0.5, 0.5]
输入 weight_2：[[2.0, 0.0], [0.0, 2.0]]，bias_2：[0.0, 0.0]

输出 y：tensor ([2.453, 9.24])，dtype=float16，shape=[2]

示例 3：多维张量计算（float16，3D输入，x=全1）

输入 x：shape=[2, 4, 64]，dtype=float16，全部元素为 1.0，weight_1=I(64×64)，bias_1=0，weight_2=I，bias_2=0

输出 y：shape=[2, 4, 64]，dtype=float16，每个元素均为 0.731（即 Swish(1.0) × 1.0 = 0.731）

六、测试用例覆盖范围

数据类型覆盖： float16

维度场景覆盖：

- 基础维度：1D 输入（无前置维度）
- 常规场景：含 batch 维、序列维的二维及三维输入
- 高维场景：大特征维度（≥256）与大前置维度乘积（M ≥ 4096）
- 非对齐场景：特征维度及前置各维度为非32整倍数（如 d=13、177）

前置维度形态覆盖：

- 单一前置维度（如仅 batch）
- 多重前置维度（如 batch × 序列长度）
- 前置维度为1（退化场景）

边界场景覆盖：

- 最小特征维度：d=1
- 数值边界：输入/权重/偏置含较大值，验证 Swish 在 float16 范围内的溢出与精度稳定性
- 具体维度组合上限以显存/内存可行性为准，测试用例会控制在合理显存占用范围内

我的提交记录

暂无提交记录